

AGENTE 10-K

Explicación de los pasos tomados en la práctica

El baseline, visto entero

GOLDEN SET COMPLETO · 20 PREGUNTAS × 3 REPETICIONES

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	63,3	54,8	50,0	83,3	50,0	1,64	20,3	3,95	1,35	15,7

LA MISMA TABLA, POR FAMILIA DE PREGUNTA

Familia	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Numéricas (6)	100	—	100	100	—	0,50	11,9	2,00	0,06	3,8
Extractivas (6)	100	100	—	100	66,7	2,07	23,4	3,72	2,67	20,5
Comparativas (8)	8,3	20,8	12,5	58,3	37,5	2,17	24,4	5,58	1,33	20,9

Leer XBRL y buscar texto nunca fueron el problema. El agujero son las comparativas: **1 de 8**, y además las más caras. Ponía la variación en «cifra» y 10 de 24 respuestas salían solo con XBRL, sin cita.

A1 • Guardrails

Problema

Ponía la variación en «cifra» (7 de 8 comparativas), podía entrar en bucle y no tenía regla para decir «no está».

Cómo

Límite de 8 llamadas y 1 read_section · verificadores de cifra y de cita · esquema estricto · prompt de honestidad con la convención de cifra.

Resultado

Cifra 50 → 100 % con una línea de prompt, y más barato. Efecto secundario: busca menos texto.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	75,0 +11,7	64,3 +9,5	100 +50,0	75,0 -8,3	50,0 ±0	1,41 -0,23	17,1 -3,2	3,25 -0,70	0,92 -0,43	11,9 -3,8
POR FAMILIA										
Numéricas (6)	100 ±0	—	100 ±0	100 ±0	—	0,54 +0,04	9,0 -2,9	1,78 -0,22	0,00 -0,06	4,4 +0,6
Extractivas (6)	100 ±0	100 ±0	—	100 ±0	66,7 ±0	1,58 -0,49	17,9 -5,5	2,72 -1,00	1,72 -0,95	13,5 -7,0
Comparativas (8)	37,5 +29,2	37,5 +16,7	100 +87,5	37,5 -20,8	37,5 ±0	1,93 -0,24	22,7 -1,7	4,75 -0,83	1,00 -0,33	16,3 -4,6

Δ frente al baseline · golden original, 20 preguntas × 3 repeticiones

A2 · Reescritura y filtros

Problema

Recall pobre: el fragmento con la respuesta solo aparecía en el top-5 la mitad de las veces.

Cómo

Filtros de metadatos forzados (ticker, año, Item) y reescritura de la consulta a inglés técnico con el propio LLM.

Resultado

Recall 50 → 64 % y ni una respuesta cambiada: las 20 con el mismo veredicto. Latencia +71 %.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	75,0 ±0	64,3 ±0	100 ±0	76,7 +1,7	64,3 +14,3	1,44 +0,03	29,4 +12,3	3,48 +0,23	1,05 +0,13	12,7 +0,8
POR FAMILIA										
Numéricas (6)	100 ±0	—	100 ±0	100 ±0	—	0,55 +0,01	10,4 +1,4	1,83 +0,05	0,00 ±0	4,6 +0,2
Extractivas (6)	100 ±0	100 ±0	—	100 ±0	50,0 -16,7	1,83 +0,25	42,7 +24,8	3,00 +0,28	2,00 +0,28	16,2 +2,7
Comparativas (8)	37,5 ±0	37,5 ±0	100 ±0	41,7 +4,2	75,0 +37,5	1,82 -0,11	33,6 +10,9	5,08 +0,33	1,12 +0,12	16,2 -0,1

Δ frente a A1 · golden original, 20 preguntas × 3 repeticiones

A3 · Búsqueda híbrida

Problema

Términos exactos (DMA, VaR) que el embedding denso no captura bien.

Cómo

BM25 + búsqueda densa, con los dos rankings fusionados por RRF, sobre la consulta ya reescrita.

Resultado

Recall 64 → 86 %. Acierto 75 → 76,7 %: una pregunta, dentro del ruido. Buscar mejor no cambia lo que responde.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	76,7 +1,7	66,7 +2,4	100 ±0	76,7 ±0	85,7 +21,4	1,40 -0,04	23,9 -5,5	3,60 +0,12	1,10 +0,05	12,2 -0,5
POR FAMILIA										
Numéricas (6)	100 ±0	—	100 ±0	100 ±0	—	0,58 +0,03	11,6 +1,2	1,89 +0,06	0,00 ±0	4,8 +0,2
Extractivas (6)	100 ±0	100 ±0	—	100 ±0	83,3 +33,3	1,91 +0,08	34,5 -8,2	3,39 +0,39	2,33 +0,33	17,0 +0,8
Comparativas (8)	41,7 +4,2	41,7 +4,2	100 ±0	41,7 ±0	87,5 +12,5	1,63 -0,19	25,2 -8,4	5,04 -0,04	1,00 -0,12	14,1 -2,1

Δ frente a A2 · golden original, 20 preguntas × 3 repeticiones

A4 • Procedimiento de comparativas

Problema
5 comparativas «mudas»: respondían solo con XBRL, sin buscar texto ni citar.

Cómo
Prompt con procedimiento: dos get_xbrl_fact con el mismo concepto, la variación, el porqué en el MD&A y el ajuste por split.

Resultado
Comparativas 41,7 → 100 %: el original queda al 100 %. El precio: la latencia pasa de 24 a 48 s.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	100 +23,3	100 +33,3	100 ±0	100 +23,3	85,7 ±0	1,59 +0,19	48,3 +24,4	3,63 +0,03	1,38 +0,28	13,8 +1,6
POR FAMILIA										
Numéricas (6)	100 ±0	—	100 ±0	100 ±0	—	0,60 +0,02	16,0 +4,4	1,67 -0,22	0,00 ±0	5,2 +0,4
Extractivas (6)	100 ±0	100 ±0	—	100 ±0	83,3 ±0	2,01 +0,10	64,1 +29,6	3,44 +0,05	2,39 +0,06	18,5 +1,5
Comparativas (8)	100 +58,3	100 +58,3	100 ±0	100 +58,3	87,5 ±0	2,02 +0,39	60,7 +35,5	5,25 +0,21	1,67 +0,67	16,8 +2,7

Δ frente a A3 • golden original, 20 preguntas × 3 repeticiones

A5 • Presupuesto por herramienta

Problema
En el difícil, preguntas de 6 compañías o 2×2×2 datos agotaban el límite global de 8: contaba llamadas, no turnos.

Cómo
Límite por herramienta según su coste: XBRL 16, búsqueda 6, lectura 1. El modelo pide hasta 6 cifras por turno.

Resultado
Difícil 72,2 → 83,3 %, todo en multi-compañía y multi-año (42,9 → 71,4). El original sigue al 100 %.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Original (20)	100 ±0	100 ±0	100 ±0	100 ±0	85,7 ±0	1,47 -0,12	49,7 +1,4	3,45 -0,18	1,30 -0,08	12,9 -0,9
Difícil (18)	83,3 +11,1	100 ±0	75,0 +16,7	100 ±0	100 ±0	2,34 +0,45	53,7 +14,6	5,39 +0,22	1,11 +0,17	16,0 +2,3
POR FAMILIA • GOLDEN DIFÍCIL										
Honestidad (5)	100 ±0	—	—	100 ±0	—	0,94 -0,18	23,5 -0,9	2,00 -0,20	0,40 -0,20	7,8 -2,4
Multi-compañía (6)	83,3 ±0	100 ±0	80,0 ±0	100 ±0	100 ±0	1,48 +0,09	36,0 +2,8	4,33 ±0	0,33 ±0	9,9 +0,6
Multi-cía. y año (7)	71,4 +28,5	100 ±0	71,4 +28,5	100 ±0	100 ±0	4,08 +1,21	90,5 +35,7	8,71 +0,71	2,29 +0,58	27,0 +7,2

Δ frente a A4 • original: 1 repetición en A5 frente a 3 en A4 • difícil: 18 preguntas × 1 repetición

A6 · Cifras de texto

Problema

VaR y sensibilidades del Item 7A: bien en prosa, pero «cifra» vacía porque no están en XBRL.

Cómo

Contrato para cifras que solo existen en el texto y verificador que exige que la cifra aparezca dentro de la cita.

Resultado





Difícil 83,3 → 94,4 %; multi-año al 100 %.
Único fallo: gY-009, un margen operativo que no quiso calcular.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Original (20)	100 ±0	100 ±0	100 ±0	100 ±0	85,7 ±0	1,86 +0,39	39,4 -10,3	3,20 -0,25	1,15 -0,15	12,7 -0,2
Difícil (18)	94,4 +11,1	100 ±0	91,7 +16,7	100 ±0	100 ±0	2,25 -0,09	46,6 -7,1	5,22 -0,17	1,17 +0,06	17,6 +1,6
POR FAMILIA · GOLDEN DIFÍCIL										
Honestidad (5)	100 ±0	—	—	100 ±0	—	1,05 +0,11	28,1 +4,6	2,00 ±0	0,40 ±0	9,5 +1,7
Multi-compañía (6)	83,3 ±0	100 ±0	80,0 ±0	100 ±0	100 ±0	2,31 +0,83	46,1 +10,1	4,83 +0,50	0,67 +0,34	16,1 +6,2
Multi-cía. y año (7)	100 +28,6	100 ±0	100 +28,6	100 ±0	100 ±0	3,05 -1,03	60,2 -30,3	7,86 -0,85	2,14 -0,15	24,6 -2,4

Δ frente a A5 · 1 repetición en ambos golden

La escalera de arquitecturas: qué aporta y qué cuesta cada cambio

—●— Golden original (20 preg.; 3 reps hasta A4, 1 rep en A5-A6) —●— Golden difícil v2 (18 preg. × 1 rep)



Cada peldaño añade lo que dice su etiqueta al anterior. Media de las repeticiones; la barra vertical es el rango mín-máx. Recall difícil: 4 anclas, cada acierto vale 25 puntos.

Cada peldaño ataca un fallo visto en las trazas

Peldaño	Qué añade	Fallo que atacaba	Original	Difícil
baseline	El agente de clase, congelado	—	63,3	61,1
A1 guardrails	Límites, verificadores, esquema estricto	Variación en «cifra»; sin «no está»	75,0	72,2
A2 reescritura	Filtros forzados + consulta en inglés	Recall@5 del 50 %	75,0	72,2
A3 híbrido	BM25 + denso, fusionados con RRF	Términos exactos: DMA, VaR	76,7	72,2
A4 comparativas	2 años, mismo concepto, MD&A y split	5 comparativas «mudas», sin cita	100	72,2
A5 límites	Presupuesto por herramienta (16/6/1)	Límite global agotado en 2 vueltas	100 ¹	83,3
A6 cifras de texto	Contrato + verificador cifra-en-cita	VaR y sensibilidades con cifra vacía	100 ¹	94,4

Los saltos vinieron de **decirle al agente cómo trabajar** (A1, A4, A5, A6), no de buscar mejor: A2 y A3 subieron el recall de 50 a 86 % sin mover una pregunta.

Lo que probamos y no funcionó

Mejor retriever

Recall de 50 a 86 % con reescritura e híbrido. Cero respuestas cambiadas: el agente ya encontraba.

Forzar filtros

Iba a ser la ganancia de A2. El 100 % de las búsquedas del baseline ya llevaba ticker.

Límite más alto

O dinámico por pregunta. El fallo era contar llamadas en vez de turnos, no el número.

Traducir el corpus

Al español. Rompe la verificación de citas literales.

Re-trocear

Las anclas ya caían dentro de un fragmento. El cuello de botella estaba en el agente.

Calculadora

0 errores aritméticos en 159 respuestas con cálculo. Atacaba un fallo que no existe.

Lo que funcionó atacaba un fallo **visto en las trazas**; lo que no, un fallo **supuesto**.

Preguntas ciegas en clase: 10 de 10

El examen

10 preguntas que no habíamos visto: 3 numéricas (2 sin dato en el corpus), 3 extractivas y 4 comparativas.

Cómo se ejecutó

evaluar() sobre el clon entregado, con A6 y sin tocar código. Puntuado con la verdad del JSONL del profesor.

Resultado

10/10, igual que el golden propio: Δ 0 pp. Las dos preguntas sin dato, respondidas con fuente = ninguna.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Golden propio (20)	100	100	100	100	85,7	1,86	39,4	3,20	1,15	12,7
Hold-out (10)	100 ±0	100 ±0	100 ±0	100 ±0	85,7 ±0	1,69 -0,17	44,9 +5,5	3,30 +0,10	1,10 -0,05	13,8 +1,1
HOLD-OUT POR FAMILIA · Δ FRENTE A LA MISMA FAMILIA DEL GOLDEN										
Numéricas (3)	100 ±0	—	100 ±0	100 ±0	—	0,77 +0,10	21,7 +7,1	1,67 +0,17	0,00 ±0	7,1 +1,3
Extractivas (3)	100 ±0	100 ±0	—	100 ±0	100 +16,7	2,69 -0,20	55,4 -1,5	3,00 +0,50	2,00 +0,17	19,8 +4,9
Comparativas (4)	100 ±0	100 ±0	100 ±0	100 ±0	75,0 -12,5	1,63 -0,35	54,5 +9,7	4,75 -0,25	1,25 -0,25	14,4 -1,8

Hold-out: 10 preguntas × 1 repetición, cada una = 10 pp · Δ frente al golden propio con A6 · commit eaf5490

Anexo • El baseline en el golden difícil

GOLDEN DIFÍCIL • 18 PREGUNTAS × 1 REPETICIÓN

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	61,1	50,0	76,9	100	75,0	1,46	23,3	5,50	1,28	12,2

LA MISMA TABLA, POR FAMILIA DE PREGUNTA

Familia	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Honestidad (5)	80,0	—	—	100	—	1,27	20,1	3,20	1,40	12,5
Multi-compañía (6)	66,7	0,0	100	100	100	1,23	25,3	5,00	0,83	9,6
Multi-cía. y año (7)	42,9	66,7	57,1	100	66,7	1,79	23,9	7,57	1,57	14,2

Pincha en lo que mezcla varias compañías y años: **3 de 7**, con 7,6 llamadas por pregunta. En multi-compañía no cita nunca (cita 0 %), y en honestidad acierta 4 de 5.

Anexo · A1 · Guardrails

Problema

Sin regla para decir «no está» y sin límites: la fuente se etiquetaba mal y nada frenaba un bucle.

Cómo

Límite de 8 llamadas y 1 read_section · verificadores de cifra y de cita · esquema estricto · prompt de honestidad.

Resultado

61,1 → 72,2 %: honestidad y cita al 100 %. Multi-año se queda en 42,9: el límite global de 8 se agota.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	72,2 +11,1	100 +50,0	58,3 -18,6	100 ±0	75,0 ±0	1,77 +0,31	25,4 +2,1	5,06 -0,44	0,89 -0,39	13,5 +1,3
POR FAMILIA										
Honestidad (5)	100 +20,0	—	—	100 ±0	—	1,07 -0,20	16,4 -3,7	2,40 -0,80	0,80 -0,60	10,2 -2,3
Multi-compañía (6)	83,3 +16,6	100 +100,0	80,0 -20,0	100 ±0	100 ±0	1,24 +0,01	21,3 -4,0	4,33 -0,67	0,33 -0,50	8,2 -1,4
Multi-cía. y año (7)	42,9 ±0	100 +33,3	42,9 -14,2	100 ±0	66,7 ±0	2,73 +0,94	35,5 +11,6	7,57 ±0	1,43 -0,14	20,3 +6,1

Golden difícil, 18 preguntas × 1 repetición · Δ frente a baseline · cada pregunta = 5,6 pp

Anexo · A2 · Reescritura y filtros

Problema
Recall pobre en el original: el fragmento con la respuesta solo aparecía en el top-5 la mitad de las veces.

Cómo
Filtros de metadatos forzados (ticker, año, Item) y reescritura de la consulta a inglés técnico con el propio LLM.

Resultado
Recall 75 → 100 % (4 anclas) y el mismo acierto: 72,2 %. Latencia +37 %.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	72,2 ±0	100 ±0	58,3 ±0	100 ±0	100 +25,0	1,75 -0,02	34,7 +9,3	5,06 ±0	0,89 ±0	13,1 -0,4
POR FAMILIA										
Honestidad (5)	100 ±0	—	—	100 ±0	—	0,81 -0,26	24,3 +7,9	2,00 -0,40	0,40 -0,40	6,4 -3,8
Multi-compañía (6)	83,3 ±0	100 ±0	80,0 ±0	100 ±0	100 ±0	1,20 -0,04	25,5 +4,2	4,17 -0,16	0,33 ±0	7,2 -1,0
Multi-cía. y año (7)	42,9 ±0	100 ±0	42,9 ±0	100 ±0	100 +33,3	2,91 +0,18	50,1 +14,6	8,00 +0,43	1,71 +0,28	22,9 +2,6

Anexo · A3 · Búsqueda híbrida

Problema

Términos exactos (DMA, VaR) que el embedding denso no captura bien.

Cómo

BM25 + búsqueda densa, con los dos rankings fusionados por RRF, sobre la consulta ya reescrita.

Resultado

Ningún cambio de acierto: 72,2 %. El recall ya estaba al 100 %. Latencia 35 → 40 s.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	72,2 ±0	100 ±0	58,3 ±0	100 ±0	100 ±0	1,91 +0,16	39,9 +5,2	5,28 +0,22	1,06 +0,17	13,5 +0,4
POR FAMILIA										
Honestidad (5)	100 ±0	—	—	100 ±0	—	1,29 +0,48	35,1 +10,8	2,60 +0,60	1,00 +0,60	11,7 +5,3
Multi-compañía (6)	83,3 ±0	100 ±0	80,0 ±0	100 ±0	100 ±0	1,20 ±0	25,0 -0,5	4,33 +0,16	0,33 ±0	7,8 +0,6
Multi-cía. y año (7)	42,9 ±0	100 ±0	42,9 ±0	100 ±0	100 ±0	2,97 +0,06	56,1 +6,0	8,00 ±0	1,71 ±0	19,6 -3,3

Anexo · A4 · Procedimiento de comparativas

Problema En el original, 5 comparativas «mudas» respondían solo con XBRL, sin buscar texto ni citar.	Cómo Prompt con procedimiento: dos get_xbri_fact con el mismo concepto, la variación, el porqué en el MD&A y el ajuste por split.	Resultado Sin efecto en el difícil: 72,2 %. Multi-año sigue en 42,9: no era un problema de comparar, sino de presupuesto.
--	---	---

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	72,2 ±0	100 ±0	58,3 ±0	100 ±0	100 ±0	1,89 -0,02	39,1 -0,8	5,17 -0,11	0,94 -0,12	13,7 +0,2
POR FAMILIA										
Honestidad (5)	100 ±0	—	—	100 ±0	—	1,12 -0,17	24,4 -10,7	2,20 -0,40	0,60 -0,40	10,2 -1,5
Multi-compañía (6)	83,3 ±0	100 ±0	80,0 ±0	100 ±0	100 ±0	1,39 +0,19	33,2 +8,2	4,33 ±0	0,33 ±0	9,3 +1,5
Multi-cía. y año (7)	42,9 ±0	100 ±0	42,9 ±0	100 ±0	100 ±0	2,87 -0,10	54,8 -1,3	8,00 ±0	1,71 ±0	19,8 +0,2

Anexo · A5 · Presupuesto por herramienta

Problema Preguntas de 6 compañías o 2×2×2 datos agotaban el límite global de 8: contaba llamadas, no turnos.	Cómo Límite por herramienta según su coste: XBRL 16, búsqueda 6, lectura 1. El modelo pide hasta 6 cifras por turno.	Resultado 72,2 → 83,3 %: multi-año 42,9 → 71,4 %. Pagado en latencia: 90 s por pregunta en esa familia.
--	--	---

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	83,3 +11,1	100 ±0	75,0 +16,7	100 ±0	100 ±0	2,34 +0,45	53,7 +14,6	5,39 +0,22	1,11 +0,17	16,0 +2,3
POR FAMILIA										
Honestidad (5)	100 ±0	—	—	100 ±0	—	0,94 −0,18	23,5 −0,9	2,00 −0,20	0,40 −0,20	7,8 −2,4
Multi-compañía (6)	83,3 ±0	100 ±0	80,0 ±0	100 ±0	100 ±0	1,48 +0,09	36,0 +2,8	4,33 ±0	0,33 ±0	9,9 +0,6
Multi-cía. y año (7)	71,4 +28,5	100 ±0	71,4 +28,5	100 ±0	100 ±0	4,08 +1,21	90,5 +35,7	8,71 +0,71	2,29 +0,58	27,0 +7,2

Golden difícil, 18 preguntas × 1 repetición · Δ frente a A4 · cada pregunta = 5,6 pp

Anexo · A6 · Cifras de texto

Problema
VaR y sensibilidades del Item 7A: bien en prosa, pero «cifra» vacía porque no están en XBRL.

Cómo
Contrato para cifras que solo existen en el texto y verificador que exige que la cifra aparezca dentro de la cita.

Resultado
83,3 → 94,4 %: multi-año al 100 %. Único fallo: gY-009, un margen operativo que no quiso calcular.

Ámbito	Acierto	Cita	Cifra	Tray.	R@5	¢/preg.	s/preg.	Llam.	Búsq.	Tok. (k)
Total	94,4 +11,1	100 ±0	91,7 +16,7	100 ±0	100 ±0	2,25 -0,09	46,6 -7,1	5,22 -0,17	1,17 +0,06	17,6 +1,6
POR FAMILIA										
Honestidad (5)	100 ±0	—	—	100 ±0	—	1,05 +0,11	28,1 +4,6	2,00 ±0	0,40 ±0	9,5 +1,7
Multi-compañía (6)	83,3 ±0	100 ±0	80,0 ±0	100 ±0	100 ±0	2,31 +0,83	46,1 +10,1	4,83 +0,50	0,67 +0,34	16,1 +6,2
Multi-cía. y año (7)	100 +28,6	100 ±0	100 +28,6	100 ±0	100 ±0	3,05 -1,03	60,2 -30,3	7,86 -0,85	2,14 -0,15	24,6 -2,4